Elhadji Diaraff DIAGNE

Senior Data Scientist

+223 76 29 98 69 | diagnediara@yahoo.fr | elhdiagne3.github.io/Portfolio | Bamako, Mali

Résumé professionnel

Data Scientist avec plus de 6 ans d'expérience en science des données, machine learning, détection de la fraude, Business Intelligence (BI) et analyse de données à grande échelle dans des environnements Cloud tels que JupyterHub, SAS Viya et Databricks. Expert confirmé dans la conception, le développement et le déploiement de cas d'usage à forte valeur ajoutée, permettant d'améliorer la performance opérationnelle, d'orienter les décisions stratégiques et de soutenir la transformation des organisations à travers les données.

Compétences techniques

- **Langages :** Python, PySpark, SQL, SAS (Studio & Analytics), R, Bash
- **Machine Learning & Deep Learning :** Scikit-Learn, TensorFlow, PyTorch, Keras, XGBoost, Hugging Face
- **IA Générative & LLM :** OpenAI API, LangChain, RAG, Prompt Engineering
- **Manipulation & Extraction :** Pandas, NumPy, Scrapy, BeautifulSoup
- **Ingénierie de Données & ETL/ELT :** Apache Airflow, Google Dataflow, dbt, Apache Spark
- **Data Warehousing & Cloud :** Google BigQuery, Databricks, Cloudera, Snowflake, GCP
- **Visualisation & Web :** Power BI, SAS Visual Analytics, D3.js, Chart.js, Streamlit, FastAPI
- **MLOps, DevOps & Outils :** Git, Docker, CI/CD, MLflow

Expérience professionnelle

Data Scientist Nov. 2020 – Présent

Orange-Mali *Bamako, Mali*

- **Cas d'usage Fraude & Revenu Assurance :** Conception et déploiement de solutions d'analyse prédictive et de tableaux de bord décisionnels sur des volumes massifs de données télécom (**SAS Viya, Python, PySpark, SQL, Power BI**), optimisant la détection de la fraude et la préservation du chiffre d'affaires.
- **Développement d'une plate-forme Web & IA (FastAPI, PySpark, Hive) :** Conception d'une application d'entreprise multi-modules connectée à Hive via PySpark, sécurisée par gestion des accès :
  - **Suivi de l'activité :** Formulaire dynamique et KPI interactifs pour le pilotage des déploiements et du niveau d'automatisation des projets.
  - **Fast-Profiling Client :** Module d'analyse instantanée du comportement client basé sur les usages Voix, SMS et Data.
  - **Monitoring Fraude :** Intégration de dashboards décisionnels dynamiques dédiés à la surveillance des anomalies réseau.
  - **Ordonnancement & MLOps :** Interface d'automatisation et de planification d'exécution des scripts & modèles ML (.py, .ipynb, .sh) offrant une autonomie totale aux utilisateurs.
  - **Assistant IA / GenAI (RAG) :** Déploiement d'une solution RAG sur les données agrégées, permettant la requête en langage naturel des KPI métiers et accélérant la prise de décision.
- **Social Media & Scraping Web :** Développement d'une solution d'extraction automatisée (**Facebook-Scraper, Streamlit**) pour l'analyse comportementale et la maîtrise des différents modes opératoires des fraudeurs sur les services Data mobiles.
- **Modélisation Prédictive Machine Learning :** Conception, entraînement et mise en production d'un modèle **XGBoost** dédié à la détection proactive de la fraude Simbox sur notre réseau télécom.

Data Analyst Août 2020 – Nov. 2020

Centre de services scolaire de Montréal (CSDM) *Montréal, Canada*

- **Pilotage des KPI de réussite scolaire :** Traitement, analyse approfondie et modélisation de données d'apprentissage afin de fournir aux conseillers scolaires des indicateurs clés et des rapports décisionnels de haute qualité.

- **Collecte & Digitalisation des données :** Conception et implémentation d'applications web de collecte de données en ligne pour optimiser la centralisation et la fiabilité des informations.

Développeur en IA Mars 2020 – Juil. 2020

Innovation Maritime *Rimouski, Canada*

- **Ingénierie de données & ETL :** Conception du pipeline d'extraction et de traitement (ETL) des données maritimes hébergées sur SQL Server via le framework RODBC de R, dans le cadre du projet de prévision du niveau de la mer pour la navigation sécurisée (stations Vieux-Québec, Saint-François et Saint-Joseph).
- **Modélisation prédictive Machine Learning :** Évaluation comparative de plusieurs architectures de séries temporelles (ARIMA, Prophet, LSTM) et mise en production du modèle ARIMA récurrençant des prédictions toutes les 3 minutes.
- **Automatisation & Monitoring :** Automatisation du flux d'exportation des prédictions vers OneDrive et développement d'un système de suivi dynamique en temps réel (Dygraphs / R) pour l'analyse des écarts entre valeurs prédites et observées.

Assistant de recherche & d'enseignement Mai 2018 – Sept. 2019

UQTR – Département de mathématiques et d'informatique *Trois-Rivières, Canada*

- **Recherche Appliquée :** Travaux comparatifs entre méthodes classiques (Analyse Discriminante, Régression) et algorithmes récents (Machine Learning, Perceptron Multicouche) pour la classification supervisée.
- **Encadrement Pédagogique :** Formation, suivi et assistance des étudiants de premier cycle en probabilités et statistique.

Statisticien, Responsable régional (RGE) Fév. 2016 – Jan. 2018

Agence nationale de la statistique et de la démographie (ANSD) *Dakar, Sénégal*

- **Supervision Terrain :** Formation et encadrement de 15 équipes d'enquêteurs et de superviseurs régionaux (Diourbel et Louga) pour garantir l'intégrité et la qualité de la collecte microdémographique.
- **Traitement & Reporting :** Gestion, apurement et analyse approfondie des données collectées, suivis de la rédaction de rapports analytiques stratégiques pour les décideurs.

Projets & Réalisations

Assistant IA & GenAI Tabulaire | *Python, LLM, RAG, LangChain*

- **Membre de l'équipe Wiito (Trois Data Scientists) :** Développement et déploiement d'une solution basée sur les architectures LLM / RAG dédiée à l'automatisation de l'analyse et de l'interrogation de données tabulaires complexes.

Plate-forme FASTProfiler | *FastAPI, SAS Viya, SQL, Géolocalisation*

- **Profilage rapide du Client :** Conception d'une plateforme d'analyse dynamique fournissant un résumé synthétique du comportement client et de ses informations d'identification sur une période donnée (profilage des usages Voix, SMS, Data, souscriptions de forfaits et géolocalisation). L'outil permet de déterminer en temps record si un client suspect présente le profil d'un fraudeur.

Modélisation du Churn Client | *PySpark, Azure Databricks, Big Data*

- **Analyse d'Attrition :** Déploiement d'un pipeline de Machine Learning sur des volumes massifs de données télécom afin d'analyser, prédire et anticiper le taux de résiliation (Churn) des clients.

Prévision Hydrographique Séries Temporelles | *Python, XGBoost, Machine Learning*

- **Prédiction des Niveaux d'Eau :** Développement et calibration d'un modèle Machine Learning XGBoost pour la prévision prédictive des niveaux de la mer au niveau de stations de surveillance au Québec.

Industrialisation de Cas d'Usage Fraude Telco | *SAS Viya, PySpark, SQL, Python*

- **Fraud Detection & Revenue Assurance :** Déploiement stratégique de plus de 30 cas d'usage de détection et de prédiction de la fraude télécom sur le réseau d'Orange Mali.

Threat Intelligence & Scraping Social Media | *Python, Web Scraping, NLP*

- **Analyse des Avis & Modus Operandi :** Conception de scripts d'extraction automatisée (Google, Facebook, YouTube) pour analyser la perception des internautes et collecter des données sur les techniques de fraude au forfait Data mobile.

Diplômes & Formations

Maîtrise en mathématiques et informatique appliquées Jan. 2018 – Sept. 2019

Université du Québec à Trois-Rivières (UQTR) *Québec, Canada*

- **Mémoire de recherche :** Analyse discriminante et perceptron multicouche : liens formels et applications. [Mémoire Sept. 2019]

Licence en statistique appliquée et informatique Nov. 2016 – Août 2017

Institut d'études et de formation en statistique, gestion (INEFSAGEP) *Dakar, Sénégal*

Technicien supérieur en statistique Oct. 2013 – Juil. 2015

École nationale de la statistique et de l'analyse économique (ENSAE) *Dakar, Sénégal*

Certifications

- **Science des données dans Azure Databricks** *[En cours]*
- **Machine Learning avec PySpark dans Azure Databricks** *Coursera [2026]*
- **Python pour la Science des données** *IBM [2020]*

Langues & Centres d'intérêt

- **Langues :** Français (Courant / Professionnel), Anglais (Intermédiaire), Arabe (Intermédiaire)
- **Centres d'intérêt :** Football, Lecture, Voyages